

## **Projet fin d'études**

### **XAI for deep time series models**

Expérimentations exploratoires et tests préliminaires

BENKHELIFA Bouchra

# Introduction


Une série temporelle est une succession d'observations collectées à intervalles réguliers dans le temps, comme la température quotidienne, la consommation d'énergie ou le cours d'une action. Elle se caractérise par plusieurs composantes principales : la tendance, qui représente l'évolution globale à long terme ; la saisonnalité, qui traduit les variations périodiques liées à des cycles connus (jour, semaine, année) ; le cycle, qui désigne les fluctuations à plus long terme souvent liées à des phénomènes économiques ou naturels ; et enfin le bruit, qui correspond aux variations aléatoires imprévisibles. Ces séries peuvent être exploitées pour faire du forecasting, c'est-à-dire la prédiction des valeurs futures à partir des données historiques. Pour cela, plusieurs approches existent : les méthodes statistiques classiques comme ARIMA, SARIMA ou le lissage exponentiel, qui reposent sur des relations linéaires entre les observations passées, mais présentent des limites lorsqu'il s'agit de modéliser des comportements complexes ou non linéaires ; et les méthodes de Deep Learning, comme les réseaux de neurones récurrents (RNN) ou LSTM, qui permettent de mieux capturer les dépendances temporelles à long terme et les interactions entre plusieurs variables. Dans ce rapport, nous allons expérimenter différentes techniques de prédiction sur des séries temporelles, comparer les méthodes traditionnelles à celles issues du Deep Learning, analyser leurs limites, puis proposer une solution finale améliorée dans la suite du travail afin de surmonter les contraintes rencontrées par les modèles de Deep Learning classiques.

# Méthodes classiques d'analyse de séries temporelles

**Le lissage exponentiel** est une méthode statistique classique qui vise principalement à réduire le bruit présent dans les données d'une série temporelle. Pour le forecasting, cette approche estime la valeur future à partir d'une moyenne pondérée des observations passées, où les poids diminuent de manière exponentielle selon un paramètre de lissage  $\alpha$  (alpha).

$$S_t = \alpha Y_t + (1 - \alpha) S_{t-1}$$

Dans cette expérimentation, j'ai appliqué la méthode de lissage exponentiel pour la prédiction des températures météorologiques sur une période de 8 mois. Le modèle a donné un MSE d'environ 2, ce qui reste satisfaisant pour une approche classique.



## Limites

Cette méthode présente certaines limites, notamment le fait qu'elle n'exploite qu'une seule variable (la température) et ignore les autres caractéristiques pouvant influencer les résultats (comme l'humidité, la pression ou la vitesse du vent). Elle est donc univariée, ce qui limite sa capacité à capturer la complexité réelle du phénomène étudié.

**C'est pour cela qu'on cherche à améliorer les performances de prévision en utilisant des méthodes plus avancées, notamment celles issues du deep learning.**


# Méthodes DL pour l'analyse de séries temporelles

Dans une série temporelle, les données sont ordonnées dans le temps. Le RNN reçoit donc les observations une par une, tout en conservant une trace (état caché) des informations précédentes. Cet état est mis à jour à chaque time step — c'est-à-dire à chaque instant temporel  $t$  pour capturer les dépendances temporelles entre les valeurs passées et présentes.

Chaque time step correspond à une fenêtre temporelle (par exemple, les 10 ou 30 derniers jours) utilisée comme contexte pour prédire la valeur suivante ou plusieurs valeurs futures.

$$h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$$

Lors de l'expérimentation avec le réseau de neurones récurrent (RNN), j'ai obtenu un RMSE **d'environ 1 °C**, ce qui représente une amélioration notable par rapport au modèle de lissage exponentiel (RMSE  $\approx 3$  °C).



## Limites

Cependant, les RNN classiques peuvent avoir du mal à capturer les dépendances **longues** (sur plusieurs centaines de pas de temps), d'où l'apparition d'architectures améliorées comme les **LSTM & Transformers**.

# Conclusion

En conclusion, le choix de la méthode d'analyse d'une série temporelle ne dépend pas uniquement de l'utilisation de modèles complexes comme les réseaux de neurones, mais surtout de la nature et de la structure des données elles-mêmes.

Il est essentiel de prendre en compte plusieurs facteurs tels que la qualité et la quantité des données disponibles, le nombre de variables (features), la complexité du phénomène étudié, ainsi que le niveau de dépendance temporelle entre les observations.

Les méthodes statistiques classiques, comme le lissage exponentiel, restent efficaces et suffisantes pour des séries simples et peu bruitées, tandis que les approches de deep learning, telles que les RNN ou les Transformers, deviennent plus pertinentes lorsque les données sont riches, multidimensionnelles et non linéaires.

Ainsi, une bonne stratégie de prévision consiste à adapter la méthode au contexte des données plutôt qu'à rechercher systématiquement le modèle le plus sophistiqué.

Dans la suite de ce travail, nous envisageons d'utiliser une série temporelle plus complexe afin de comparer plus en profondeur les performances entre le RNN et le **Transformeur**, **dans le but d'identifier la méthode la plus robuste pour le forecasting.**